真实拉曼谱的矿物分类

如何评价模型对未见标本的预测?

石英、方解石与石膏

52条实测谱，22个RRUFF标本ID

来源方已处理的数据库谱图

本专题的机器学习问题

输入与目标

输入501个波数变量，预测石英、方解石或石膏。

模型与验证

比较简单谱匹配、线性分类和核模型，按标本隔离。

需要解释的结果

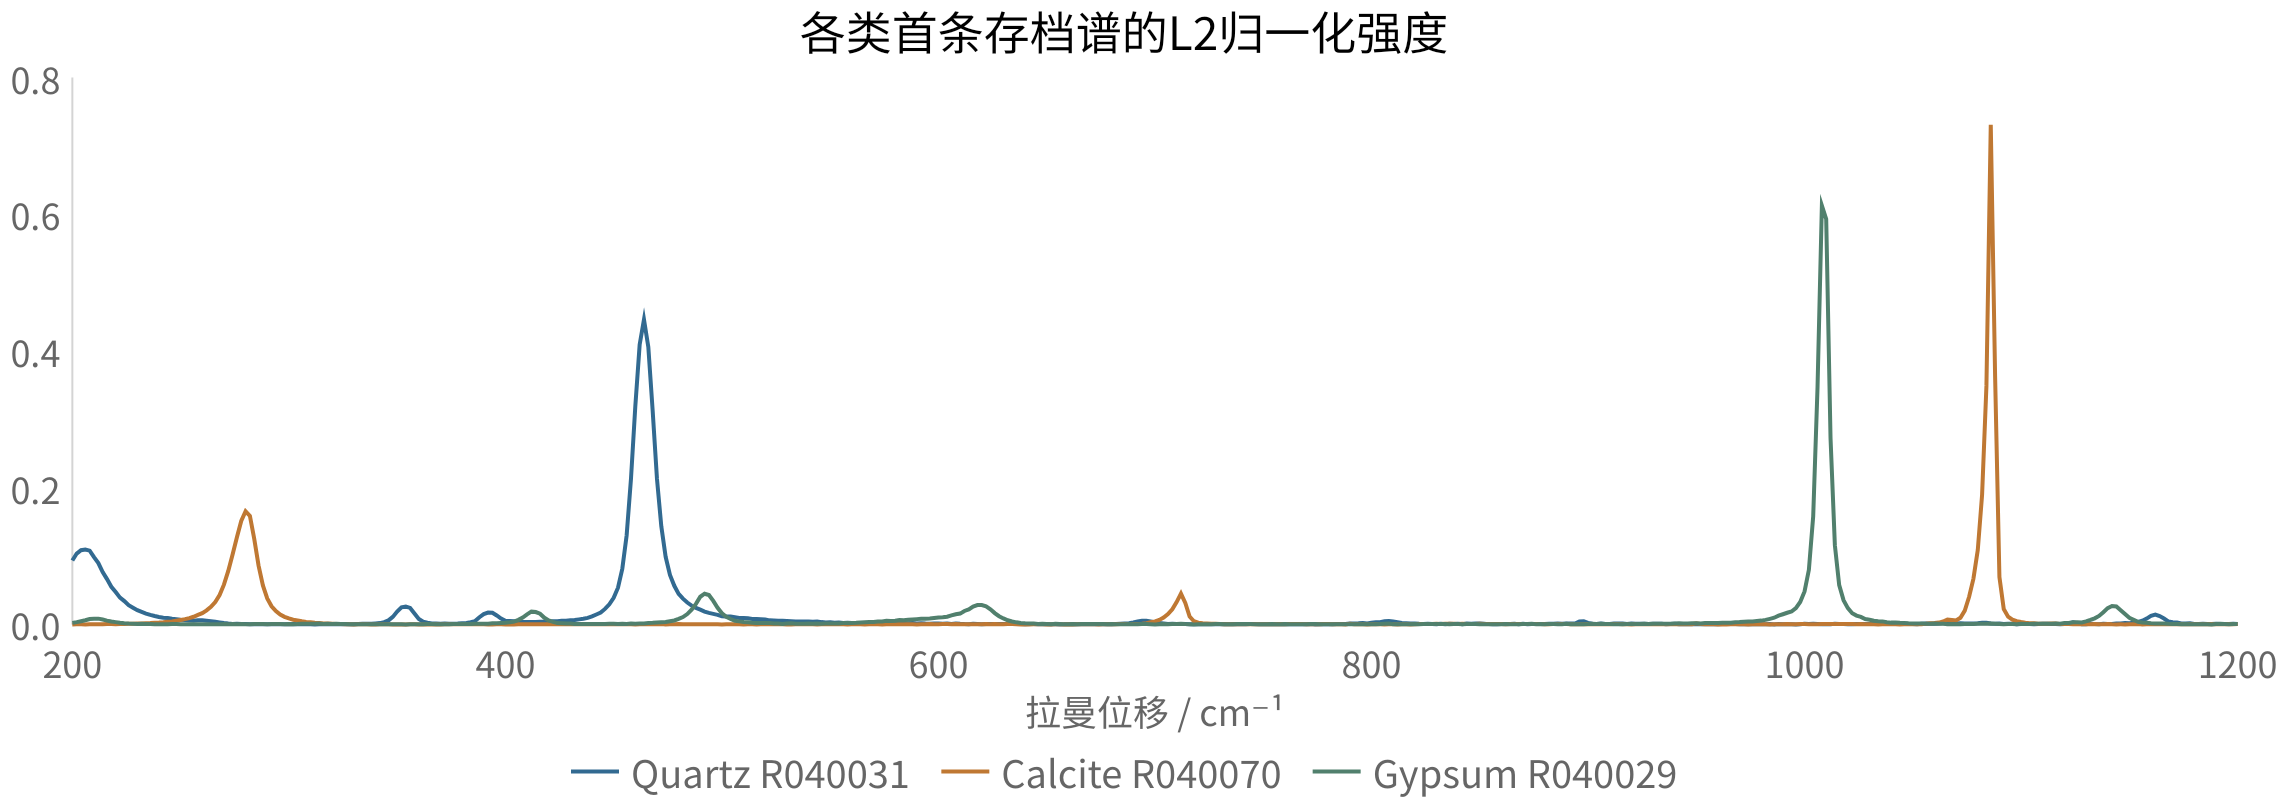
模型是否优于多数类？高分覆盖了哪些对象与条件？

数据来源与独立样本数

矿物	实测谱数	RRUFF标本ID数
石英 Quartz	21	10
方解石 Calcite	26	10
石膏 Gypsum	5	2
合计	52	22

Li、Schmidt、Alstrøm，DTU数据集v1（2022），CC BY 4.0。
DOI: 10.11583/DTU.20222331.v1。本组筛选三类并转换格式。

实测谱形示例



相似峰形支持分类；同一标本的多条谱仍可能高度相关。

22折按标本留出验证

每折完整留出一个标本ID

该ID的所有谱同时进入验证侧，与训练侧无ID重叠。

训练折内拟合完整流程

PCA、变量标准化与分类器只从其余标本学习。

汇总所有折外预测

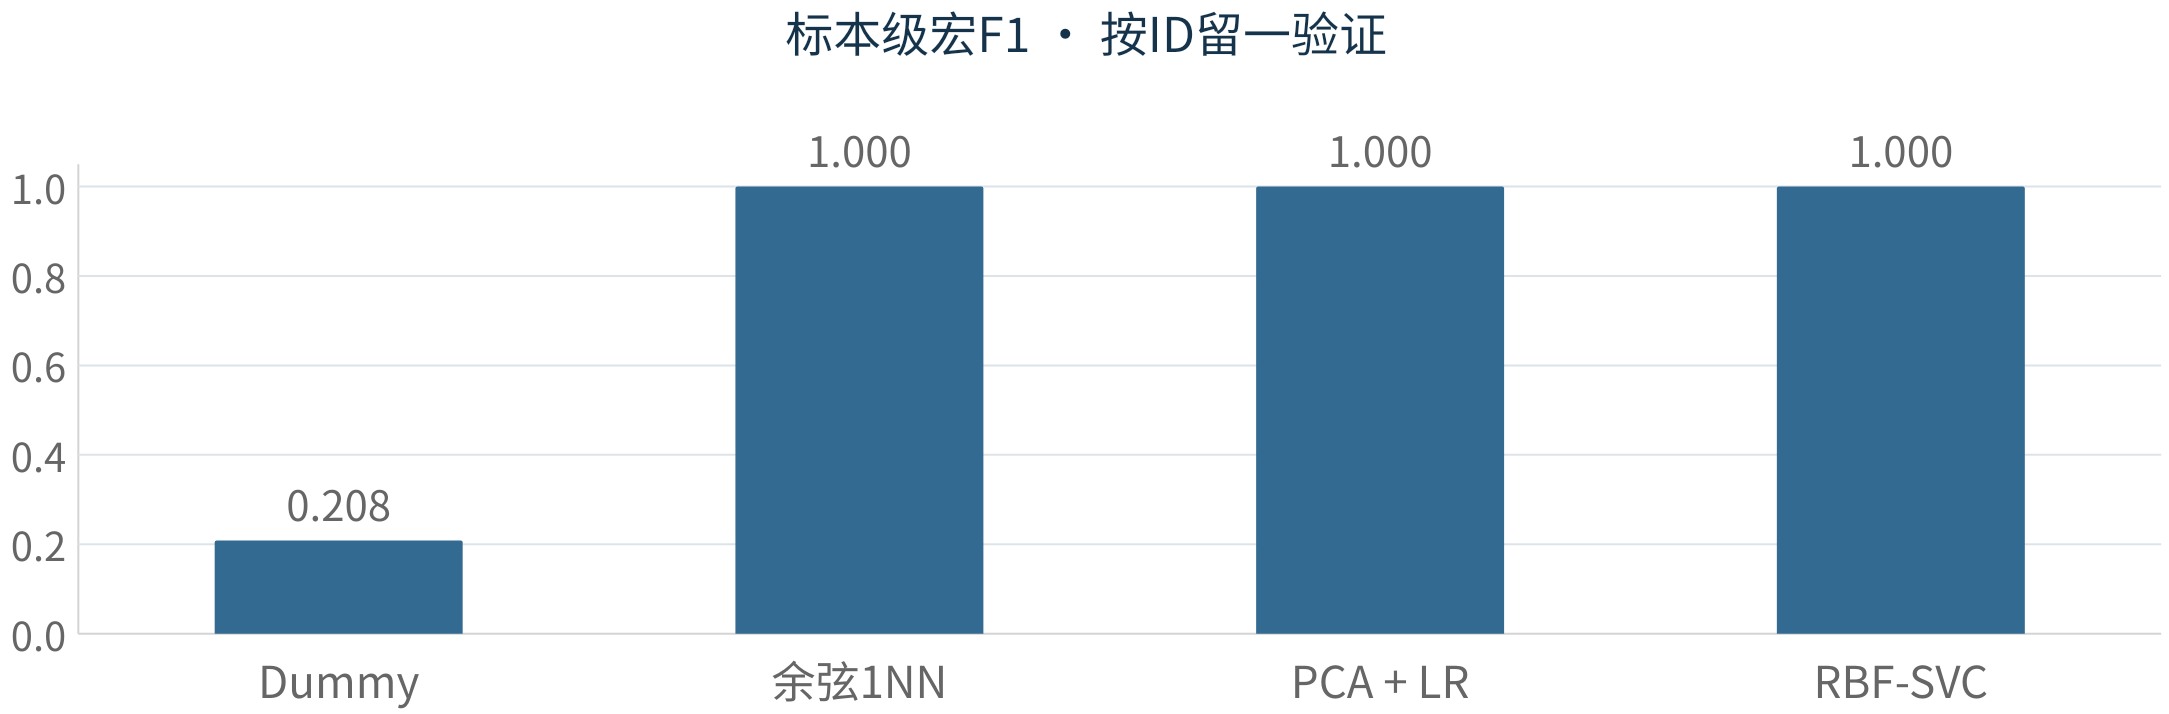
先逐谱预测，再按ID多数投票；主指标每个标本等权。

四个模型在评估前固定

模型	处理与固定参数
Dummy	多数类基线
Cosine_1NN	逐谱L2，余弦距离1近邻
PCA8_LR	L2，标准化，PCA 8维，LR C=1
RBF_SVC	逐谱L2，C=10，gamma=scale

固定波数区间200–1200 cm^{-1}，步长2 cm^{-1}，无数据增强。

三个分类模型均识别22个标本



当前小子集容易区分，尚未显示复杂模型优于简单谱匹配。

高分的解释边界

石膏仅有两个标本

新增独立标本，比增加同一标本的重复扫描更有价值。

本轮是数据库内验证

尚无独立外部测试，无法推出实际应用正确率100%。

来源处理与仪器身份有限

原谱已处理；激光波长不能代替仪器ID或配对关系。

模拟教学对照的独立用途

模拟模块	用于解释
90个标本，540条生成谱	重复扫描与标本身份的区别
随机划分与分组划分	训练和验证共享身份导致的乐观偏差
A/B域与预处理比较	受控背景变化及完整处理流程的影响

上述A/B下降与arPLS增益，只属于模拟结果。

离线演示与程序复现

浏览实测谱

选一条谱，读出矿物标签、标本ID、激光波长和来源。

检查验证结果

切换Dummy与分类模型，观察折外预测和混淆矩阵。

在自己的电脑复现

运行程序，检查52条谱/22个ID与指标，记录环境和输出。

近年前沿与验证要求

REFORMS（2024）：研究报告规范

公开独立单位、分析过程与复现信息，便于检查证据。

拉曼验证比较（2025）：评价设计

验证策略影响分数与排名，需匹配实际预测对象。

TabPFN（2025）：表格基础模型

提供新的小样本基线，谱学适用性仍须独立验证。

已完成的成果与下一步

可复查的真实数据案例

实测谱、来源清单、固定程序、逐条预测、图表与交互页。

组内仍需完成

独立复现、核读论述、填写实际分工并排练汇报。

提高科学证据强度

补充稀少类别及独立来源标本，再设计外部验证。