实测拉曼光谱的矿物分类

模型能否正确识别未参与训练的标本?

石英、方解石与石膏

52 条实测拉曼光谱，来自 22 个独立标本

谱图取自 RRUFF 数据库，已经来源方预处理

从光谱到矿物类别的分析流程

研究问题：模型能否判断未参与训练的标本属于石英、方解石还是石膏？

光谱表示

在统一网格上
取 501 个强度值

→

模型训练

由已知类别的光谱
学习判别规则

→

分组验证

整体留出一个标本
预测其类别

→

结果评价

比较四种方法
界定结论适用范围

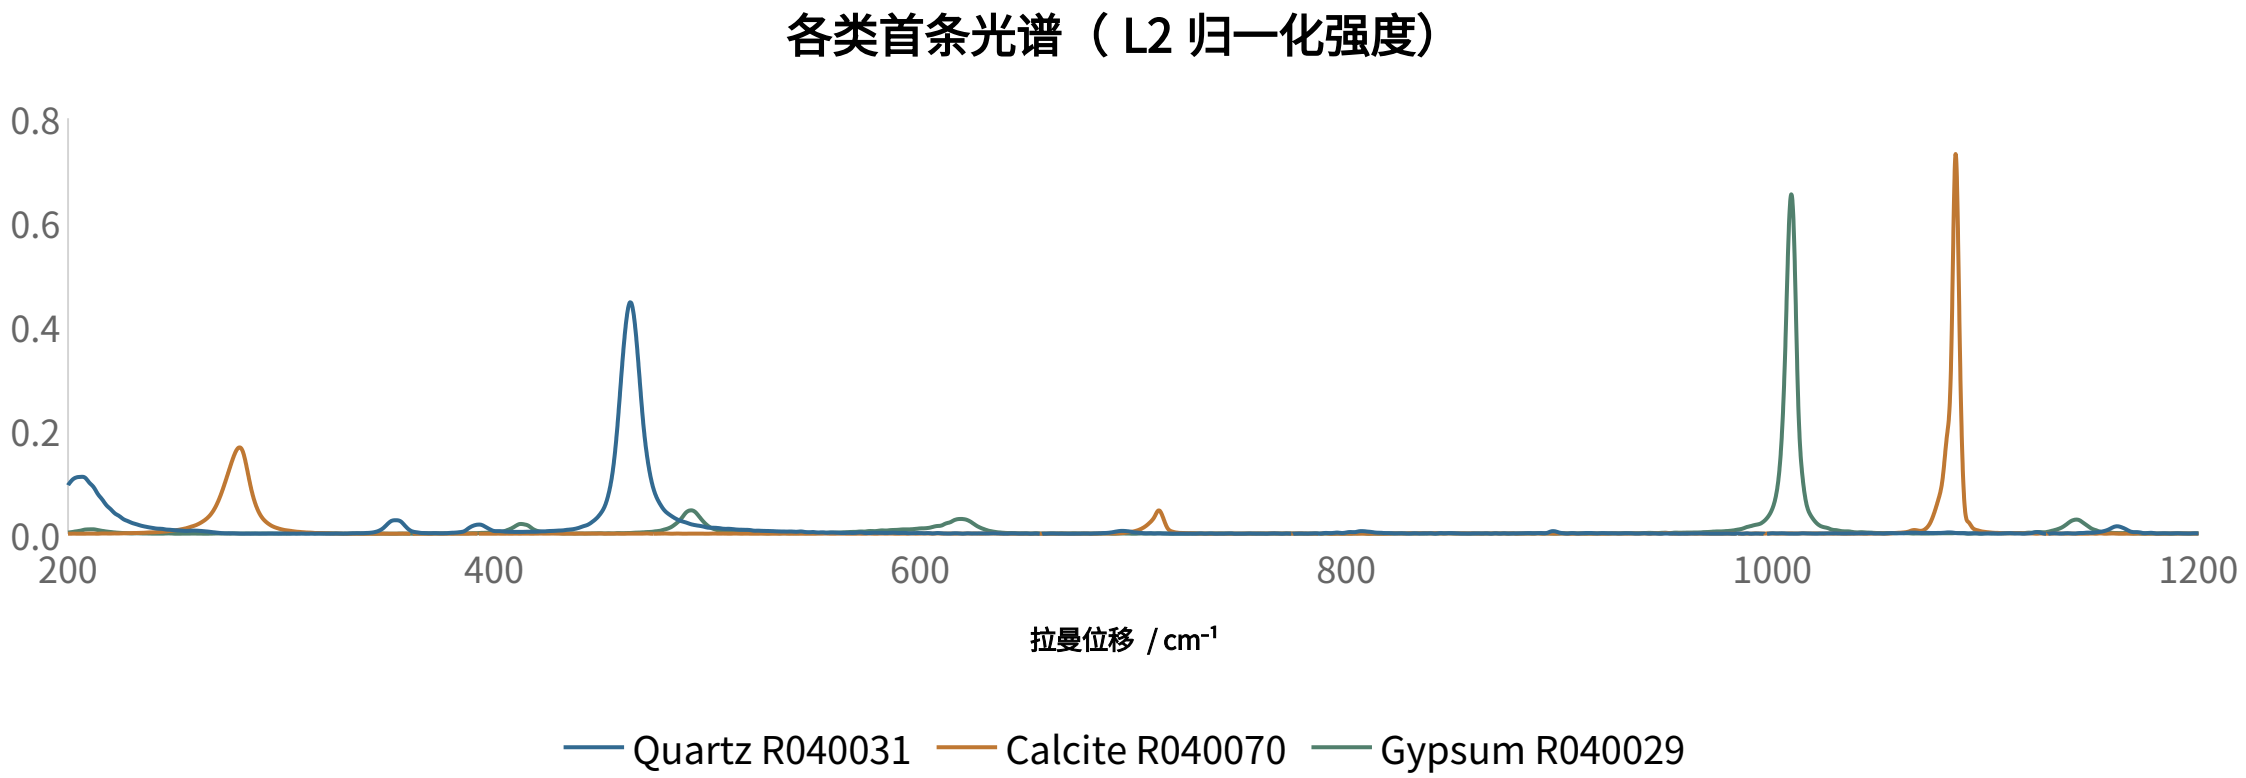
同一标本的全部光谱须一并留出，以免训练集与验证集包含同一标本。

光谱数与独立标本数

矿物	光谱数	标本数（RRUFF ID）
石英 Quartz	21	10
方解石 Calcite	26	10
石膏 Gypsum	5	2
合计	52	22

Li、Schmidt、Alstrøm，DTU 数据集 v1（2022），CC BY 4.0。
DOI: 10.11583/DTU.20222331.v1。本组仅筛选其中三类矿物并转换格式。

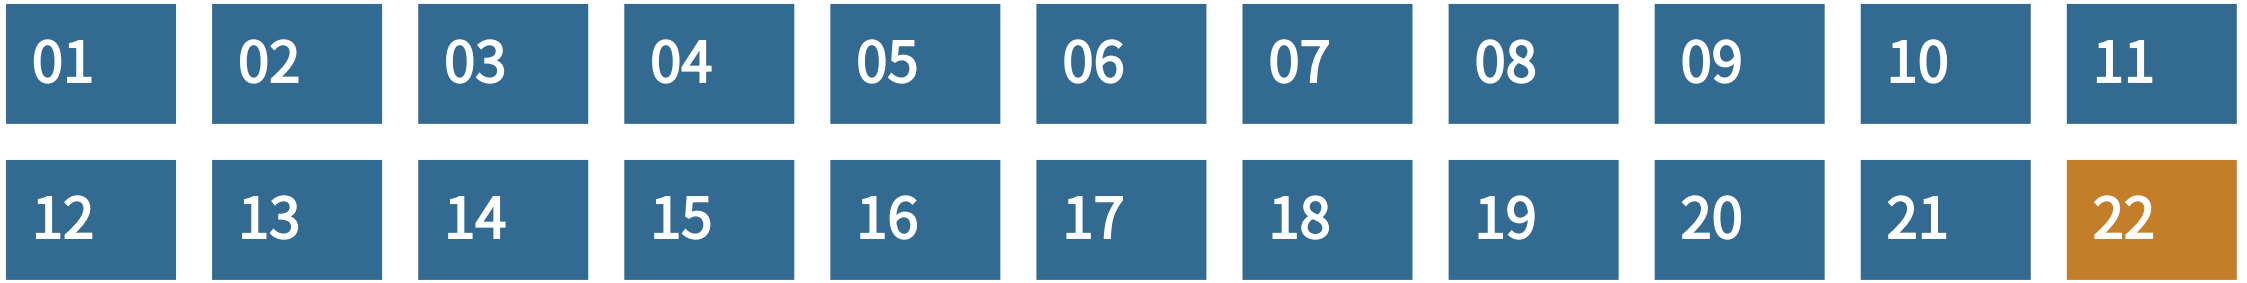
三类矿物的代表性光谱



特征峰的位置与峰形差异构成分类依据；但同一标本的多条光谱高度相关。

留一标本交叉验证（共 22 折）

每个方块代表一个标本及其全部光谱



蓝色： 21 个训练标本　　**橙色： 1 个验证标本**

依次留出每个标本，共 22 折；每个标本均在未参与训练的条件下被预测一次。

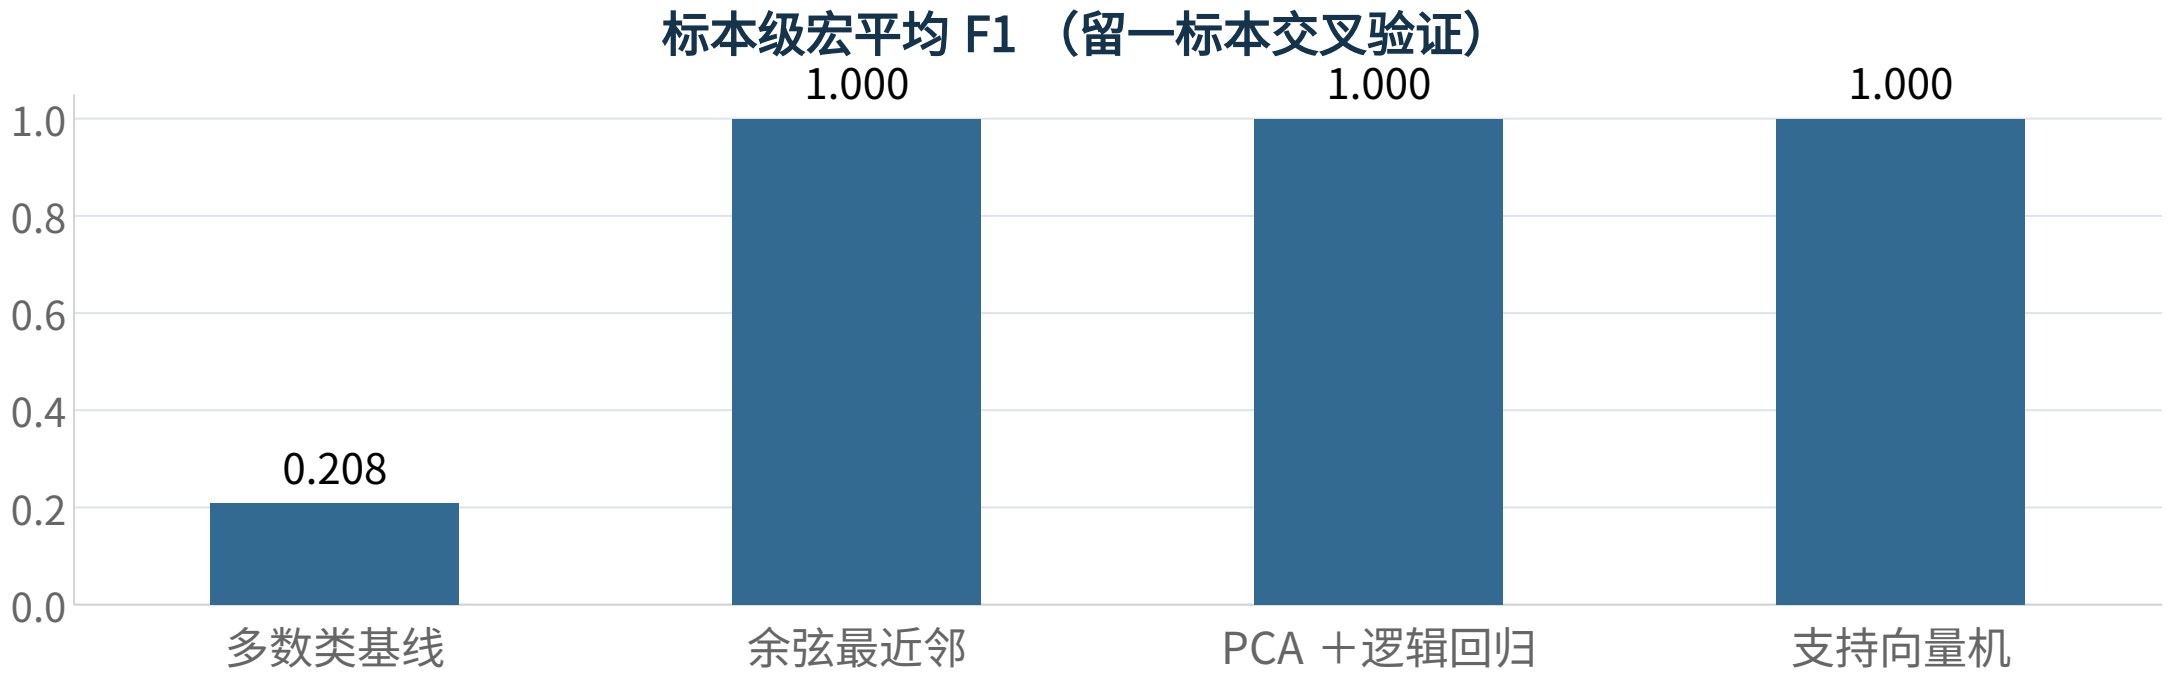
标准化与 PCA 仅在训练集上拟合；同一标本多条光谱的预测按多数投票汇总。

四种候选方法的判别原理

方法	判别原理
多数类基线	不使用光谱信息，始终预测训练集中样本最多的类别
余弦最近邻	检索余弦相似度最高的训练光谱，沿用其类别
PCA ＋逻辑回归	先以主成分分析降至 8 维，再拟合逻辑回归分类器
支持向量机（ RBF 核）	在特征空间中学习类别间的非线性决策边界

四种方法使用相同的数据与分组方案，参数预先固定，未依据验证结果调整。

最简单的余弦最近邻已达满分



三种分类方法均正确识别全部 22 个标本，多数类基线的宏平均 F1 为 0.21；该子集区分度高，不足以比较方法优劣。

满分结果的适用范围

石膏仅有两个标本

增加独立标本比重复扫描同一标本更能提高结论的可靠性。

仅为数据库内部验证

缺少独立的外部测试集，不能推断实际应用的准确率为 100% 。

仪器信息不完整

光谱已经来源方预处理，且激光波长不能代替仪器身份，无法评价跨仪器性能。

模拟实验：演示数据泄漏与仪器差异

模拟模块	用于说明
90 个标本、 540 条生成光谱	重复扫描与独立标本的区别
逐谱随机划分与按标本分组划分	训练集与验证集共享标本时的乐观偏差
仪器 A/B 与预处理对比	仪器差异造成的性能下降及预处理的影响

上述性能下降与预处理增益均为模拟结果，不代表实测光谱的表现。

现场演示：预测结果与数据泄漏

① 实测页：选取一条石膏光谱

选择光谱 9308 （标本 R040029 ），查看其参考类别与谱图。

② 比较多数类基线与余弦最近邻

多数类基线预测为方解石，余弦最近邻正确预测为石膏。

③ 模拟页：切换两种划分方式

逐谱随机划分时第 1 折共享 44 个标本；按标本分组后降为 0 。

近期研究进展

REFORMS （2024）：机器学习研究报告规范

要求报告独立单元、划分方式与复现信息，以便核查证据。

拉曼光谱验证策略比较（2025）

验证方式会改变模型得分与排序，须与实际预测对象相匹配。

TabPFN （2025）：表格基础模型

可作为小样本问题的新基线，其在光谱数据上的适用性仍需独立验证。

工作总结与后续安排

已完成内容

教材正文、图解、参考文献、六道传承题、代码与两个交互页面。

实测案例已重新运行

52 条光谱、 22 个标本，重新训练所得预测与存档结果一致。

后续安排

确认分工并排练汇报，完成 GitHub 正式提交与组间交叉评审。