拉曼矿物识别中的泛化验证

模型学到的是矿物特征，
还是重复扫描留下的标本身份？

方案一 · 可复现的三类光谱教学实验

石英 / 方解石 / 石膏 | 全部数据为模拟

本专题覆盖整章机器学习

模型族	能增加什么	需要检查什么
PLS / Ridge / Elastic Net	低维线性关系与系数收缩	共线性、变量尺度、选择稳定性
SVM / SVR / 高斯过程	核映射与局部非线性	C 、 γ 、核假设与小样本方差
随机森林 / 梯度提升	非线性交互与分段关系	早停、分组验证与重要性偏差

统一评价框架：任务定义 → 验证边界 → 指标、概率与解释

90 个标本， 540 条模拟谱

用途	物理标本数	仪器与扫描数
开发与交叉验证	72	仅 A： 216 条
最终配对留出	18	A： 54 条； B： 54 条
未使用的开发 B 谱	同一批 72 个开发标本	B： 216 条，完全排除

目标：识别未见物理标本，并检查同批新标本换仪器后的表现。

验证边界与选模顺序

开发集： 72 个标本

逐谱随机划分作为泄漏反例；按标本分组结果用于选择候选。

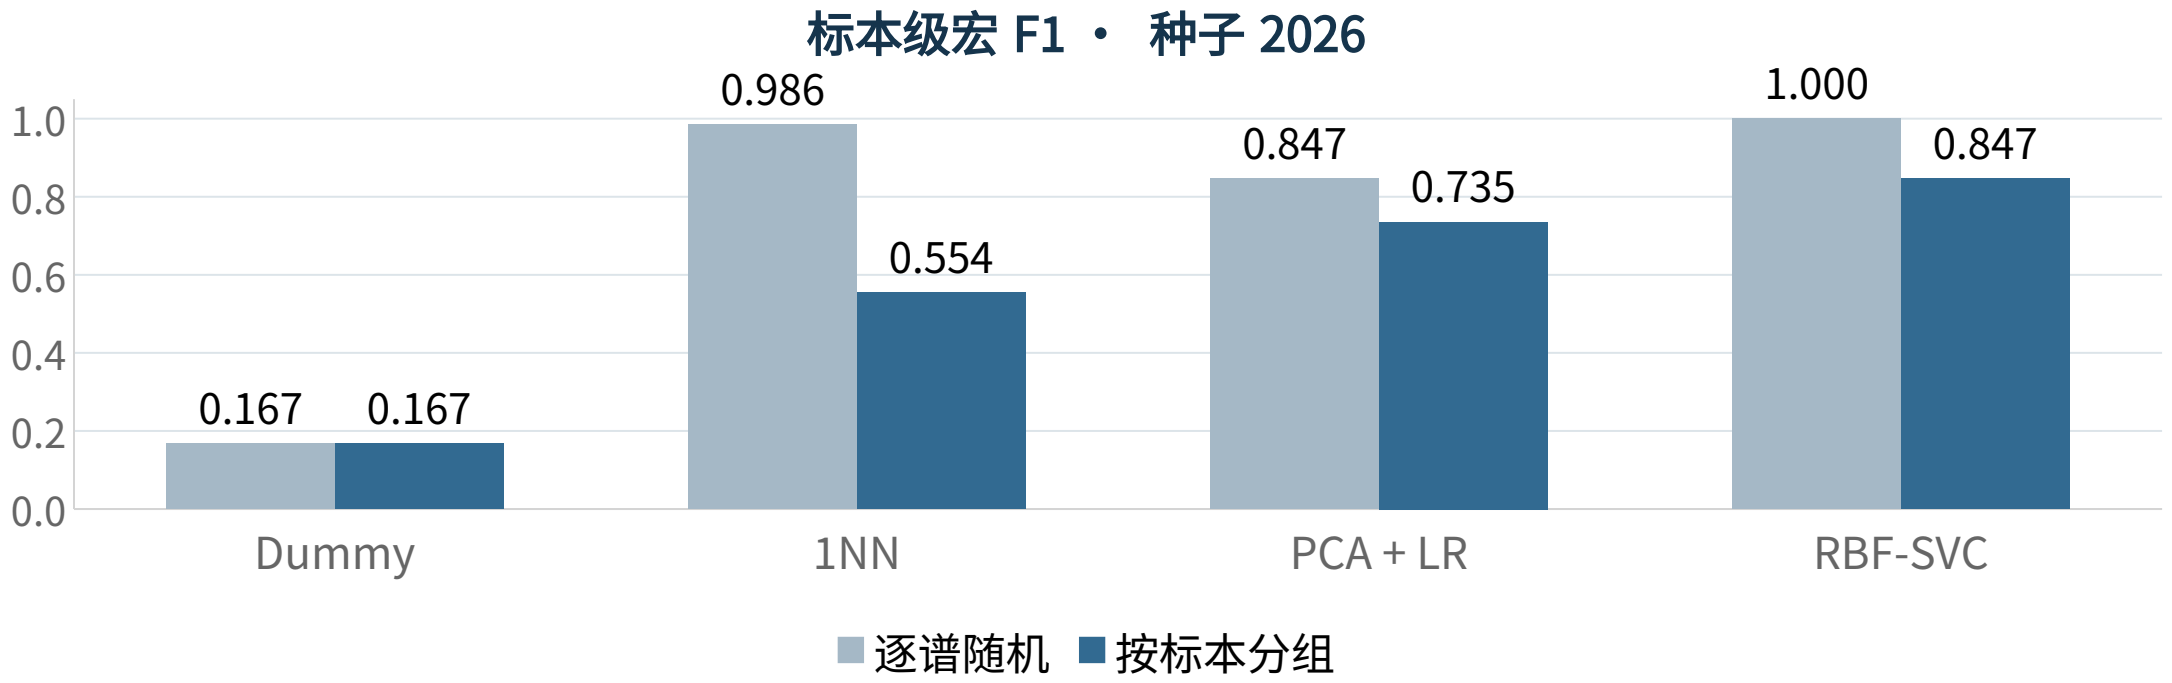
每个训练折内拟合完整 Pipeline

标准化、 PCA 与分类器均不得提前使用验证折。

流程冻结后评估 18 个留出标本

在 A 与 B 上配对预测； B 结果不反向修改当前选择。

逐谱随机划分抬高了本例分数



1NN： 0.9861 → 0.5537 。分组划分改变了“预测新对象”的难度。

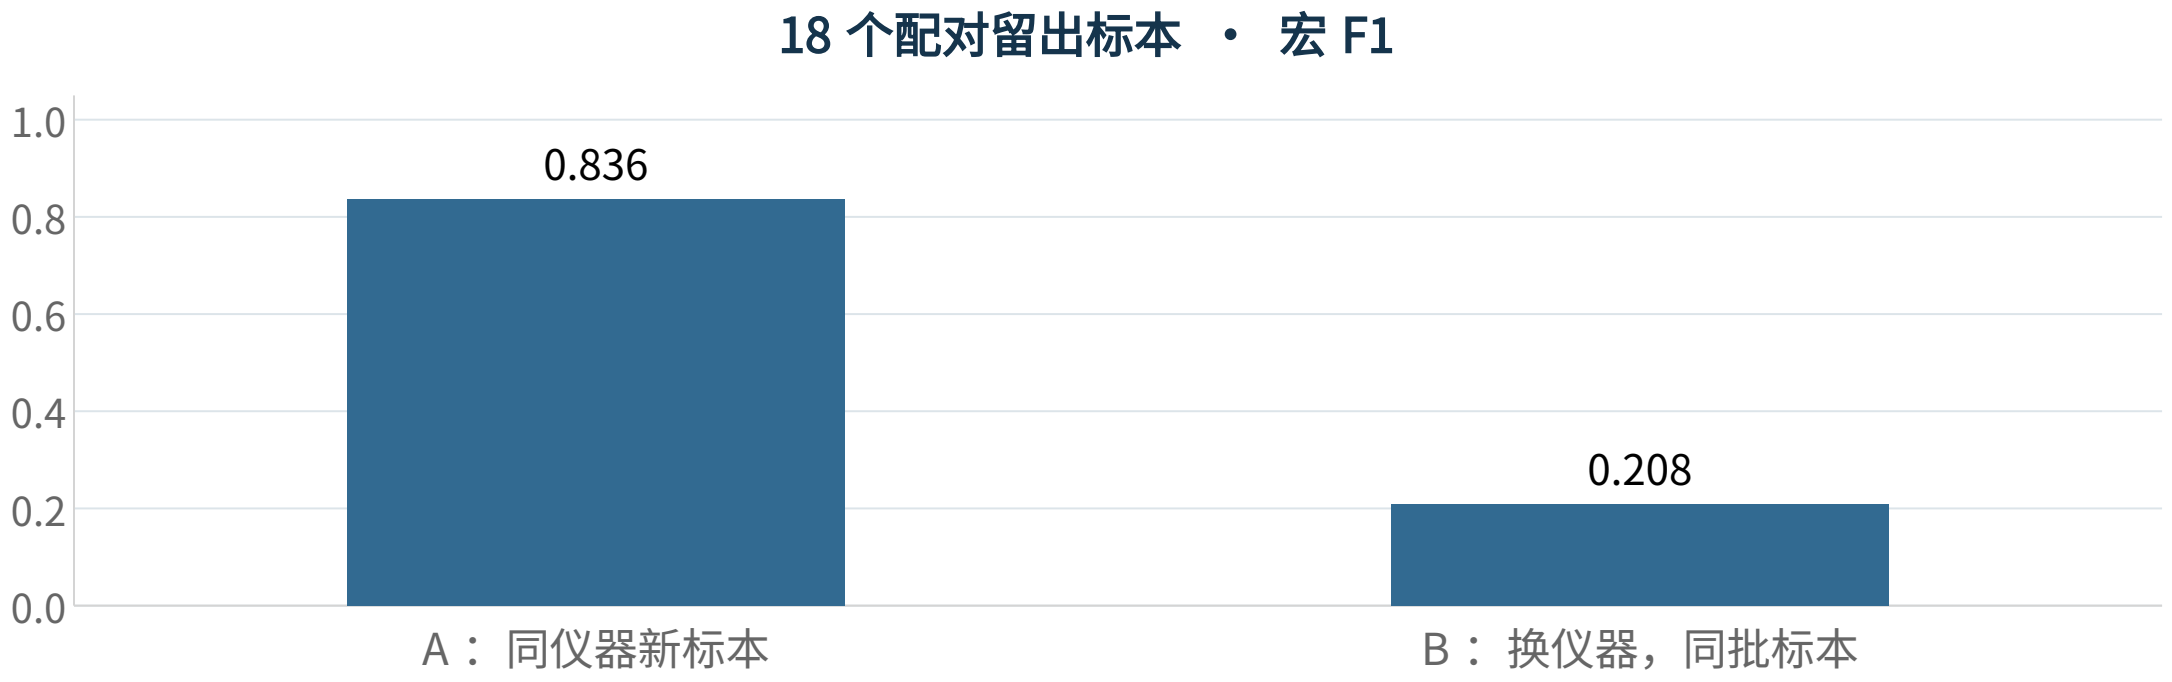
随机标签负对照揭示身份泄漏

1NN 验证方式	199 次均值	2.5%—97.5% 分位数
逐谱随机	0.9818	0.9719—1.0000
按标本分组	0.3335	0.2221—0.4583

标签已经不含矿物类别信息，逐谱随机依然接近满分。

反例说明重复扫描可以暴露标本身份；一次随机标签结果不足以概括随机性。

同一批新标本换仪器后性能下降



0.8364 → 0.2081： 在标本层面分组，仍不能保证跨仪器有效。

预处理改善了固定模拟条件下的表现

五种子均值宏 F1	开发分组 CV	A 留出	B 留出
原始标准化 + SVC	0.8916	0.9128	0.2783
arPLS + L2 + SVC	0.9972	1.0000	0.9888

组合处理改变基线与强度尺度，没有进行波数轴校准。

高分受简单三分类模拟条件限制；不能归因于单一步骤，也不是实测迁移证据。

概率校准与阈值选择也需要独立边界

分区	职责	样本量
拟合集 / 校准集	拟合分类器 / 拟合 sigmoid 校准器	1440 / 480
阈值验证集	按照预定误判代价选择阈值	240
最终测试集	冻结后报告概率与决策表现	240

本例测试 Brier： 0.069738 → 0.069828 ，略变差。

校准并不保证每次改善； Brier 也同时受区分能力和数据不确定性影响。

近年前沿为本章补充了什么

REFORMS （2024）：报告规范

把依赖关系、分析步骤与复现信息显式报告；清单本身不能保证设计正确。

拉曼验证比较（2025）：划分影响排名

不同验证策略影响估计；具体数据集结论不能替代部署场景判断。

TabPFN （2025）：表格基础模型

预训练先验提供新基线；不能默认适用于高维原始拉曼谱或跨仪器场景。

课堂演示与传承题

现场演示：切换逐谱与分组

观察训练 / 验证共享标本数、红框以及全部四折的标本级混淆矩阵。

继续切换仪器与处理流程

比较 A/B ，查看五个种子的全部结果；数值来自已保存的预测文件。

传承题：投票能否消除泄漏?

不能。把折外扫描聚合为标本预测，不会改变训练时的信息边界。

当前结论与下一步

已得到的证据

在本模拟中，重复谱泄漏可夸大分数；分组评价与域外评价回答不同问题。

目前的限制

只有三类、简化谱形与有限标本；未使用实测 RRUFF 数据，不能报告真实识别率。

真实实验的进入条件

取得独立标本和配对仪器数据，记录来源与测量条件，再冻结新的验证方案。